Лабораторная работа 2

Лабораторную работу необходимо выполнять в среде Jupyter Notebook. В качестве среды разработки можно использовать VSCode, PyCharm, Jupyter Notebook и т. д.

Пример настроенной среды для выполнения лабораторных работ находится в репозитории GitHub по адресу https://github.com/al-filippov/mai

Вся необходимая информация содержится в файле readme.md в репозитории.

Для выполнения работы необходимо уточнить свой вариант. Перечень ссылок на данные находится на странице курса в LMS в разделе «Лабораторные работы».

Шаги выполнения лабораторной работы:

1. Выбрать три набора данных, которые не соответствуют Вашему варианту задания.
2. Провести анализ сведений о каждом наборе данных со страницы загрузки в Kaggle. Какова проблемная область?
3. Провести анализ содержимого каждого набора данных. Что является объектом/объектами наблюдения? Каковы атрибуты объектов? Есть ли связи между объектами?
4. Привести примеры бизнес-целей, для достижения которых могут подойти выбранные наборы данных. Каков эффект для бизнеса?
5. Привести примеры целей технического проекта для каждой выделенной ранее бизнес-цели. Что поступает на вход, что является целевым признаком?
6. Определить проблемы выбранных наборов данных: зашумленность, смещение, актуальность, выбросы, просачивание данных.
7. Привести примеры решения обнаруженных проблем для каждого набора данных.
8. Оценить качество каждого набора данных: информативность, степень покрытия, соответствие реальным данным, согласованность меток.
9. Устранить проблему пропущенных данных. Для каждого набора данных использовать разные методы: удаление, подстановка константного значения (0 или подобное), подстановка среднего значения.
10. Выполнить разбиение каждого набора данных на обучающую, контрольную и тестовую выборки.
11. Оценить сбалансированность выборок для каждого набора данных. Оценить необходимость использования методов приращения (аугментации) данных.
12. Выполнить приращение данных методами выборки с избытком (oversampling) и выборки с недостатком (undersampling). Должны быть представлены примеры реализации обоих методов для выборок каждого набора данных.
13. Все выводы и программный код должны быть оформлены в виде ноутбука. Для выполнения данной лабораторной работы следует создать новый файл-ноутбук.
14. Разобраться с основными возможностями библиотеки imbalanced-learn (https://imbalanced-learn.org/stable/) для решения задачи приращения данных и несбалансированности выборок.
15. Разобраться с работой функции train_test_split библиотеки scikit-learn (https://scikit-learn.org/stable/).
16. Быть готовым ответить на вопросы и выполнить задания по описанным выше пунктам.
17. Полученный ноутбук следует отправить в собственный репозиторий в Git-хранилище по адресу https://git.is.ulstu.ru/

Контрольные вопросы

1. Что такое машинное обучение (МО)?
2. Какую роль в МО играют данные?
3. Что такое неструктурированные, слабоструктурированные и структурированные данные?
4. Объясните суть понятий: модель, набор данных, наблюдение, признак, входные признаки, целевой признак.
5. В каком формате могут быть представлены выходные признаки при решении задачи МО?
6. Какие выборки формируются на основе набора данных и для чего они используются?
7. Что такое конвейер машинного обучения и для чего он используется?
8. В чем разница между параметрами и гиперпараметрами модели?
9. В чем разница между классическим/поверхностным и глубоким машинным обучением?
10. Когда следует использовать методы МО?
11. Когда НЕ следует использовать методы МО?
12. Из каких этапов состоит жизненный цикл проекта МО?
13. Каковы ключевые показатели проекта МО?
14. Каковы наиболее важные свойства модели МО?
15. Перечислите основные роли в команде проекта МО.
16. Каковы основные причины провалов проекта МО?
17. В чем важность этапа сбора и подготовки данных?
18. Перечислите основные свойства качества данных в МО.
19. Перечислите основные проблемы с данными в МО и их причины.
20. Перечислите основные методы решения проблем с данными в МО.
21. Что такое просачивание данных и каковы причины просачивания данных?
22. Что такое групповое разбиение данных и для чего оно используется?
23. В чем заключается проблема отсутствия значений и каковы основные способы ее решения?
24. Для чего используется приращение (аугментация) данных?
25. В чем суть проблемы несбалансированных данных?
26. Каковы основные способы решения проблемы несбалансированных данных?
27. Перечислите основные технические средства работы с данными.