Лабораторная работа 3

Лабораторную работу необходимо выполнять в среде Jupyter Notebook. В качестве среды разработки можно использовать VSCode, PyCharm, Jupyter Notebook и т. д.

Пример настроенной среды для выполнения лабораторных работ находится в репозитории GitHub по адресу https://github.com/al-filippov/mai

Вся необходимая информация содержится в файле readme.md в репозитории.

Для выполнения работы необходимо уточнить свой вариант. Перечень ссылок на данные находится на странице курса в LMS в разделе «Лабораторные работы».

Шаги выполнения лабораторной работы:

1. Определить две бизнес-цели для набора данных по Вашему варианту задания.
2. Определить цели технического проекта для каждой выделенной ранее бизнес-цели.
3. При необходимости следует использовать методы сбора и подготовки данных, которые были рассмотрены в лекции № 2.
4. Выполнить разбиение каждого набора данных на обучающую, контрольную и тестовую выборки для устранения проблемы просачивания данных.
5. Оценить сбалансированность выборок для каждого набора данных. Применить методы приращения (аугментации) данных при необходимости.
6. Выполнить процесс конструирования признаков для решения каждой из двух задач. Задача определяется совокупностью бизнес-цели и цели технического проекта.
7. При конструировании признаков обязательно необходимо выполнить: унитарное кодирование категориальных признаков (one-hot encoding), дискретизацию числовых признаков, «ручной» синтез признаков, масштабирование признаков на основе нормировки и стандартизации.
8. Выполнить также конструирование признаков с применением фреймворка Featuretools.
9. Оценить качество каждого набора признаков по следующим критериям: предсказательная способность, скорость вычисления, надежность, корреляция и цельность.
10. Все выводы и программный код должны быть оформлены в виде ноутбука. Для выполнения данной лабораторной работы следует создать новый файл-ноутбук.
11. Разобраться с основными возможностями фреймворка Featuretools (https://featuretools.alteryx.com/en/stable/) для решения задачи автоматизации процесса синтеза признаков.
12. Быть готовым ответить на вопросы и выполнить задания по описанным выше пунктам.
13. Полученный ноутбук следует отправить в собственный репозиторий в Git-хранилище по адресу https://git.is.ulstu.ru/

Контрольные вопросы

1. Что такое признак?
2. Что такое вектор признаков?
3. Что такое пространство признаков?
4. Для чего используется конструирование признаков?

5. Влияет ли качество процесса конструирования признаков на качество полученной статистической модели?
6. Каковы особенности работы с категориальным признаками?
7. Каковы особенности работы с числовыми признаками?
8. Для чего используется дискретизация признаков?
9. Перечислите основные методы дискретизации признаков.
10. Для чего используется синтез признаков?
11. Перечислите основные методы синтеза признаков.
12. Для чего используется масштабирование признаков?
13. Перечислите основные методы масштабирования признаков.
14. Как оценить качество признаков?
15. Для чего используется отбор признаков?
16. Перечислите основные методы отбора признаков.
17. Для чего используется понижение размерности признаков?
18. Возникает ли проблема просачивания данных при конструировании признаков?
19. Перечислите основные технические средства для работы с признаками.
20. Перечислите основные рекомендации по конструированию признаков.
21. Перечислите основные технические рекомендации по конструированию признаков.