Лабораторная работа 5

Лабораторную работу необходимо выполнять в среде Jupyter Notebook. В качестве среды разработки можно использовать VSCode, PyCharm, Jupyter Notebook и т. д.

Пример настроенной среды для выполнения лабораторных работ находится в репозитории GitHub по адресу https://github.com/al-filippov/mai

Вся необходимая информация содержится в файле readme.md в репозитории.

Для выполнения работы необходимо уточнить свой вариант. Перечень ссылок на данные находится на странице курса в LMS в разделе «Лабораторные работы».

Шаги выполнения лабораторной работы:

1. Выбрать бизнес-цель для набора данных по Вашему варианту задания для решения задачи кластеризации.
2. Выполнить понижение размерности и визуализацию данных.
3. Выполнить выбор количества кластеров на основе оценки инерции и коэффициента силуэта.
4. Выполнить кластерный анализ с применением иерархического и неиерархического алгоритма кластеризации.
5. Оценить качество решения.
6. Все выводы и программный код должны быть оформлены в виде ноутбука. Для выполнения данной лабораторной работы следует создать новый файл-ноутбук.
7. Разобраться с основными возможностями библиотеки scikit-learn (https://scikit-learn.org/1.5/).
8. Быть готовым ответить на вопросы и выполнить задания по описанным выше пунктам.
9. Полученный ноутбук следует отправить в собственный репозиторий в Git-хранилище по адресу https://git.is.ulstu.ru/

Контрольные вопросы

1. В чем особенность машинного обучения без учителя?
2. Для чего используется кластерный анализ?
3. В чем особенность многомерного анализа данных?
4. В каких областях применяются методы кластерного анализа?
5. Приведите пример задачи, для решения которой необходимо использовать кластерный анализ.
6. В чем заключаются преимущества кластерного анализа?
7. В чем состоит задача кластеризации?
8. Что такое кластер?
9. Чем классификация отличается от кластеризации?
10. Чем класс отличается от кластера?
11. Что является решением задачи кластеризации?
12. Что такое характеристическая функция?
13. Какие типы характеристической функции существуют?
14. Какие требования к данным выдвигаются при решении задачи кластеризации?
15. Перечислите основные гиперпараметры алгоритмов кластеризации.
16. Что такое мера сходства и для чего она используется?
17. Какие меры сходства Вы знаете?

18. Каким образом можно представить результаты кластеризации?
19. Перечислите основные классы алгоритмов кластеризации.
20. В чем особенность иерархических алгоритмов кластеризации?
21. Перечислите основные алгоритмы иерархической кластеризации.
22. В чем особенность неиерархических алгоритмов кластеризации?
23. Перечислите основные алгоритмы неиерархической кластеризации.
24. Назовите основные базовые понятия алгоритма кластеризации.
25. Что такое вектор центров кластеров?
26. Что такое матрица разбиения?
27. Для чего используется целевая функция алгоритма кластеризации?
28. Для чего используются методы понижения размерности?
29. Перечислите основные методы понижения размерности.
30. На что влияет выбор количества кластеров?
31. Опишите базовую схему выбора количества кластеров.
32. Как можно оценить качество кластеризации?
33. Перечислите основные рекомендации для решения задачи на основе кластерного анализа.