Лабораторная работа 8

Лабораторную работу необходимо выполнять в среде Jupyter Notebook. В качестве среды разработки можно использовать VSCode, PyCharm, Jupyter Notebook и т. д.

Пример настроенной среды для выполнения лабораторных работ находится в репозитории GitHub по адресу https://github.com/al-filippov/mai

Вся необходимая информация содержится в файле readme.md в репозитории.

Шаги выполнения лабораторной работы:

1. Определить задачу анализа текстов.
2. Применить методы предобработки текста. При выполнении лабораторной требуется проверить применимость методов предобработки для получения оптимального решения задачи.
3. Определить влияние этапа выделения частей речи (и других морфологических признаков) на качество решения.
4. Применить методы нормализации текста. При выполнении лабораторной требуется проверить применимость методов нормализации для получения оптимального решения задачи.
5. Применить методы фильтрации текста. При выполнении лабораторной требуется проверить применимость методов фильтрации для получения оптимального решения задачи.
6. Определить влияние этапа формирования N-грамм на качество решения.
7. Применить методы индексирования (векторизации) текста: мешок слов, частотный портрет. При выполнении лабораторной требуется проверить применимость методов индексирования для получения оптимального решения задачи.
8. Выполнить обучение модели с учителем или без учителя для решения задачи. Оценить качество решения для различных комбинаций гиперпараметров (методы предобработки, нормализации, фильтрации, индексирования, гиперпараметры модели машинного обучения).
9. Все выводы и программный код должны быть оформлены в виде ноутбука. Для выполнения данной лабораторной работы следует создать новый файл-ноутбук.
10. Разобраться с основными возможностями следующих библиотек для решения задачи анализа текстов: spaCy (https://spacy.io/usage/), NLTK (https://www.nltk.org), scikit-learn (https://scikit-learn.org/).
11. Быть готовым ответить на вопросы и выполнить задания по описанным выше пунктам.
12. Полученный ноутбук следует отправить в собственный репозиторий в Git-хранилище по адресу https://git.is.ulstu.ru/
13. Ссылки на наборы данных (можно использовать любой или все):
    - ТЗ и статьи по ИТ (кластеризация, классификация) 719 KB https://cloud.athene.tech/f/c0fa18258eec4fd888af/
    - Записки по ПМУ (кластеризация, антиплагиат) 225 MB https://cloud.athene.tech/f/4d530ceeef1047bc91ec/
    - Научные статьи (кластеризация) 2 GB https://www.kaggle.com/datasets/thuanhuynh2004/textmining-finaldataset

Контрольные вопросы

1. Что такое NLP?
2. Назовите основные задачи в области NLP.
3. Назовите основные этапы развития методов NLP.
4. Назовите базовые этапы анализа в NLP.
5. Что такое анализ текстов?
6. В чем разница между NLP и Text mining?
7. Для чего используется этап предобработки текстов?
8. Для чего используется этап трансформации текста?
9. Для чего используется этап токенизации текста?
10. Что такое POS tagging?
11. Для чего используется этап нормализации текста?
12. Что такое стемминг?
13. Что такое лемматизация?
14. Для чего используется этап фильтрации текста?
15. Что такое стоп-слово?
16. Что такое N-грамма?
17. Для чего используется этап создания N-грамм?
18. Для чего используется этап индексирования текста?
19. Что такое мешок слов?
20. Что такое частотный портрет?
21. Как рассчитывается частота слова при формировании частотного портрета?
22. Что такое эмбединги?
23. Для чего используется синтаксический анализ?
24. Перечислите морфологические признаки слова.
25. Для чего может быть использовано дерево синтаксического разбора?
26. Что такое именованная сущность?
27. Для чего может быть использовано извлечение именованных сущностей?
28. Перечислите основные проблемы анализа текстов.
29. Перечислите основные гиперпараметры анализа текстов.
30. Какие задачи можно решать на основе результатов анализа текстов?
31. Как оценить качество решения задачи, полученного на основе методов анализа текстов?